


Ciencia de datos

Clase 1

¿Qué es la Ciencia de Datos?

La Ciencia de Datos es un campo interdisciplinario que utiliza métodos, procesos, algoritmos y sistemas científicos para **extraer conocimiento** y percepciones **de datos** estructurados y no estructurados. Implica el **análisis**, la **interpretación** y la **presentación** de estos datos.

El proceso del análisis de datos



¿Por qué es importante?

La Ciencia de Datos se ha convertido en una disciplina crítica en la toma de decisiones empresariales y la investigación debido a su capacidad para **revelar patrones, tendencias y conocimiento oculto en los datos**. Algunas de las aplicaciones comunes incluyen:

- Predicción del comportamiento del cliente.
- Diagnóstico médico.
- Análisis financiero.
- Optimización de procesos.
- Análisis de sentimientos en redes sociales.
- Y mucho más.

Herramientas para Ciencia de Datos

Python es uno de los lenguajes de programación más utilizados en la Ciencia de Datos debido a su ecosistema de bibliotecas y herramientas. Algunas de las bibliotecas populares son:

- NumPy: para operaciones matemáticas.
- Pandas: para manipulación de datos tabulares.
- Matplotlib y Seaborn: para visualización de datos.
- Scikit-Learn: para aprendizaje automático (Machine Learning).
- TensorFlow y PyTorch: para aprendizaje profundo (Deep Learning).
- Jupyter: para la creación de cuadernos interactivos.

Flujo de trabajo de Ciencia de Datos

1. Obtención de datos: Recopilar datos de diversas fuentes como bases de datos, archivos, API, web, etc.
2. Limpieza de datos: Identificar y corregir datos faltantes, duplicados o erróneos.
3. Exploración de datos: Realizar análisis exploratorio para comprender la estructura y distribución de los datos.
4. Preparación de datos: Transformar los datos en un formato adecuado para el análisis.
5. Análisis de datos: Utilizar técnicas estadísticas y de visualización para extraer información relevante.
6. Modelado y Aprendizaje Automático: Construir modelos predictivos o descriptivos utilizando algoritmos de Machine Learning.
7. Evaluación del modelo: Evaluar el rendimiento del modelo utilizando métricas apropiadas.
8. Comunicación de resultados: Presentar los resultados de manera efectiva a las partes interesadas.

Ejemplo de Análisis de Datos con Python

```
import pandas as pd

# Cargar datos
data = pd.read_csv('datos.csv')

# Exploración de datos
print(data.head())
print(data.describe())

# Preparación de datos
data = data.dropna()

# Visualización
import matplotlib.pyplot as plt
data['columna'].hist()
plt.show()
```

Conclusiones

- La Ciencia de Datos es una disciplina que utiliza datos para tomar decisiones informadas.
- Python es una herramienta poderosa en este campo debido a su ecosistema de bibliotecas.
- El flujo de trabajo típico de Ciencia de Datos implica obtener, limpiar, explorar, analizar y modelar datos.
- La comunicación efectiva de resultados es esencial.